

# Modélisation statistiques

aurore.lavigne@univ-lille.fr

# Plan du cours

## 1 Vecteurs aléatoires

# Notations et définitions

Soit  $(\Omega, \mathcal{A}, \mathbb{P})$  un espace de probabilité et  $p$  un entier positif.

## Définition

On appelle vecteur aléatoire de dimension  $p$  (ou variable aléatoire  $p$ -dimensionnelle) le vecteur

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}, \text{ où les } X_i \text{ sont des v.a réelles.}$$

Les v.a .  $X_i, i = 1, \dots, p$  sont appelées les marginales de  $\mathbf{X}$ .

- $\mathbf{X}$  est donc une application définie par :

$$\begin{aligned} \mathbf{X} : \Omega &\longrightarrow \mathbb{R}^p \\ \omega &\longrightarrow \mathbf{X}(\omega) = \begin{pmatrix} X_1(\omega) \\ \vdots \\ X_p(\omega) \end{pmatrix} \end{aligned}$$

- La loi de  $\mathbf{X}$  est caractérisée par sa fonction de répartition (appelée aussi fonction de distribution) jointe définie par

$$F(\mathbf{x}) = \mathbb{P}(X_1 \leq x_1, \dots, X_p \leq x_p),$$

pour tout  $\mathbf{x} = (x_1, \dots, x_p)^T$ .

- On distingue essentiellement deux grands types vecteurs aléatoires :
  - **Vecteur aléatoire discret.** Si pour tout  $i = 1, \dots, p$ ,  $\Omega(X_i)$  est un sous-ensemble fini ou dénombrable de  $\mathbb{R}$  alors  $\Omega(\mathbf{X})$  est un sous-ensemble fini ou dénombrable de  $\mathbb{R}^p$ . On dit alors que  $X$  est un vecteur aléatoire discret. Sa distribution est dite discrète.
  - **Vecteur aléatoire continu.** Si pour tout  $i = 1, \dots, p$ ,  $\Omega(X_i)$  n'est pas un sous-ensemble fini ou dénombrable de  $\mathbb{R}$ . On dit alors que  $\mathbf{X}$  est un vecteur aléatoire continu. Sa distribution est dite absolument continue par rapport à la mesure de Lebesgue dans  $\mathbb{R}^d$ .

# Le théorème de Radon-Nikodym

## Théorème

Si  $\mathbf{X}$  est un vecteur aléatoire continu, alors il existe une fonction  $f : \mathbb{R}^p \longrightarrow \mathbb{R}$  mesurable telle que

$$\forall B \in \mathcal{B}, \mathbb{P}(\mathbf{X} \in B) = \int_B f(\mathbf{x}) d\mathbf{x}.$$

On dit que  $f$  est la **fonction de densité de probabilité** (pdf) de  $\mathbf{X}$  (ou densité jointe des composantes de  $\mathbf{X}$ ).

## Propriété.

$$f(\mathbf{x}) \geq 0 \text{ pour tout } \mathbf{x} \in \mathbb{R}^p \text{ et } \int_{\mathbb{R}^p} f(\mathbf{x}) d\mathbf{x} = 1.$$

Dans le cas d'un vecteur aléatoire discret, les équivalents de la pdf sont les probabilités

$$p_i = \mathbb{P}(\mathbf{X} = \mathbf{x}_i)$$

où les  $\mathbf{x}_i$  sont les valeurs possibles de  $\mathbf{X}$ , attention il s'agit de vecteurs.

	cas continu	cas discret
Valeurs possibles	$\mathbf{x}$	$\mathbf{x}_i$
loi de $\mathbf{X}$ (pdf/probabilités)	$f(\mathbf{x})$	$p_i$

# Espérance et moments d'un vecteur aléatoire

- L'espérance d'un vecteur aléatoire  $\mathbf{X}$  est définie par

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_p) \end{pmatrix}.$$

- De manière général si  $g : \mathbb{R}^p \longrightarrow \mathbb{R}^q$  est une fonction mesurable, on a

$$\mathbb{E}(g(\mathbf{X})) = \begin{pmatrix} \mathbb{E}(g_1(\mathbf{X})) \\ \vdots \\ \mathbb{E}(g_q(\mathbf{X})) \end{pmatrix}.$$

- On suivra la même règle si  $g$  est à valeurs dans un espace de matrices.



# Variance d'un vecteur aléatoire

La notion de variance peut s'étendre aux vecteurs aléatoires de la manière suivante :

## Définition

Si  $\mathbf{X}$  est un vecteur aléatoire de dimension  $p$  alors :

$$\mathbb{V}(\mathbf{X}) = \mathbb{E} \left[ (\mathbf{X} - \mathbb{E}\mathbf{X}) (\mathbf{X} - \mathbb{E}\mathbf{X})^T \right] = (\sigma_{ij})_{1 \leq i, j \leq p},$$

avec

$$\begin{aligned} \sigma_{ij} &= \text{Cov}(X_i, X_j) = \mathbb{E} [(X_i - \mathbb{E}X_i)(X_j - \mathbb{E}X_j)] \\ &= \mathbb{E}(X_i X_j) - \mathbb{E}(X_i)\mathbb{E}(X_j) \end{aligned} .$$

$\mathbb{V}(\mathbf{X})$  est connue sous le nom de matrice de variance-covariance de  $\mathbf{X}$ . Elle est souvent notée  $\Sigma_X$  ; nous adoptons cette notation.

## Propriétés

1.  $\Sigma_X$  est une matrice symétrique définie positive.
2. Si  $A$  est une matrice  $q \times p$  déterministe, alors

$$\mathbb{E}(A\mathbf{X}) = A\mathbb{E}(\mathbf{X}) \text{ et } \Sigma_{A\mathbf{X}} = A\Sigma_{\mathbf{X}}A^T.$$

## Rappel

- On dit qu'une matrice  $M$  est définie positive si pour tout vecteur  $u$ ,  $u^T M u > 0$ .
- Ou bien de manière équivalente toutes les valeurs propres de  $M$  sont positives.
- D'autre part, une combinaison linéaire de matrices définies positives de même dimension est définie positive.
- Enfin, le théorème spectral entraîne que si  $M$  est symétrique (définie positive), alors il existe une matrice orthogonale  $P$  et une matrice diagonale  $D$  telle que  $M = P D P^T$ .
- On en déduit qu'il existe une matrice  $A$ , telle que  $M = A A^T$  ; par exemple  $A = P D^{1/2}$ .

Preuve.

1. La matrice  $\Sigma_X$  est symétrique par construction. En effet, elle s'écrit comme l'espérance d'une matrice symétrique<sup>1</sup>.

Montrons que  $\Sigma_X$  est définie positive. Soit le vecteur  $u = (u_1, \dots, u_p)^T$ . Alors, on a par définition de l'espérance :

$$\begin{aligned} u^T \Sigma_X u &= \mathbb{E} \left\{ \left[ u^T X - \mathbb{E} (u^T X) \right] \left[ u^T X - \mathbb{E} (u^T X) \right]^T \right\} \\ &= \mathbb{V} (u^T X) = \mathbb{V} \left( \sum_{j=1}^p u_j X_j \right) \geq 0. \end{aligned}$$

2. Evident pour l'espérance, par définition. Pour la variance, on a :

$$\mathbb{V} (AX) = \mathbb{E} \left\{ [AX - \mathbb{E} (AX)] [AX - \mathbb{E} (AX)]^T \right\} = A \Sigma_X A^T.$$

---

1. le produit d'un vecteur et de sa transposée est toujours symétrique.

## Remarque

Plus généralement, on peut définir la covariance de deux vecteurs aléatoires  $X$  et  $Y$ , de dimension  $p$  par

$$\mathbb{C}ov(X, Y) = \mathbb{E} \left[ (X - \mathbb{E}X) (Y - \mathbb{E}Y)^T \right]$$

Attention au fait que contrairement au cas de la dimension 1, si  $X$  et  $Y$  sont des vecteurs aléatoires on a en général :

$$\mathbb{C}ov(X, Y) \neq \mathbb{C}ov(Y, X).$$

## Propriété

Si  $A$  et  $B$  sont des matrices déterministes alors

$$\mathbb{C}ov (AX, BX) = A \Sigma_X B^T.$$

- Dans ce cours, on traite uniquement le cas des vecteurs aléatoires continus.
- Ainsi, on considère le vecteur aléatoire

$$\mathbf{X} = (X_1, \dots, X_p)^T$$

où les  $X_i$  sont des v.a. unidimensionnelles continues, avec des densités de probabilités respectives

$$f_1(x_1), \dots, f_p(x_p),$$

et de fonctions de répartition respectives

$$F_1(x_1), \dots, F_p(x_p).$$

et la densité de probabilité jointe des composantes de  $\mathbf{X}$  est

$$f(x_1, \dots, x_p)$$

- La loi de  $\mathbf{X}$  est caractérisée par sa fonction de répartition (appelée aussi fonction de distribution) jointe

$$F(x_1, \dots, x_p) = \mathbb{P}(X_1 \leq x_1, \dots, X_p \leq x_p).$$

- On a

$$F(x_1, \dots, x_p) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_p} f(u_1, \dots, u_p) du_1 \dots du_p,$$

où  $f(x_1, \dots, x_p)$  est la fonction densité de probabilité jointe de  $\mathbf{X}$ .

- Si les  $X_i, i = 1, \dots, p$  sont des **v.a. indépendantes** alors

$$f(x_1, \dots, x_p) = \prod_{i=1}^p f_i(x_i) \text{ et } F(x_1, \dots, x_p) = \prod_{i=1}^p F_i(x_i).$$

- Réciproquement, si les factorisations précédentes sont vraies, alors les  $X_i, i = 1, \dots, p$  sont des v.a indépendantes.



- L'hypothèse d'indépendance des  $X_i$  permet donc de simplifier considérablement les calculs.
- Pour cette raison, plusieurs méthodes statistiques supposent toujours l'indépendance des variables aléatoires étudiées.
- Mais il faut faire attention au fait que l'hypothèse d'indépendance est parfois difficile à vérifier en pratique.

## Définition

Soit  $X$  une variable aléatoire  $p$ -dimensionnelle. La densité jointe  $g$  d'une partie des composantes de  $X$  est obtenue en intégrant la densité jointe de  $X$  dans le domaine des variables qui ne sont pas dans la partie considérée. Ainsi, si l'on re-numérote les composantes de  $X$  par

$$X_1, \dots, X_q, X_{q+1}, \dots, X_p$$

alors on peut écrire

$$g(x_1, \dots, x_q) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_p) dx_{q+1} \dots dx_p.$$

- On obtient également la fonction de distribution jointe  $G$  associée par

$$\begin{aligned} G(x_1, \dots, x_q) &= \mathbb{P}(X_1 \leq x_1, \dots, X_q \leq x_q) \\ &= F(x_1, \dots, x_q, +\infty, \dots, +\infty). \end{aligned}$$

- En particulier la densité marginale d'une variable  $X_i$  s'écrit :

$$f_i(x_i) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f(x_1, \dots, x_p) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_p.$$

Exemple.

Soient  $Y_1$  et  $Y_2$  deux variables aléatoires réelles indépendantes et de même loi. On note par  $g$  et  $G$  la fonction de densité et la fonction de répartition de ces variables. On définit

$$X_1 = \min\{Y_1, Y_2\} \text{ et } X_2 = \max\{Y_1, Y_2\}.$$

1. La densité de  $X = (X_1, X_2)$  est donnée par

$$f(x_1, x_2) = \begin{cases} 2g(x_1)g(x_2) & \text{si } x_1 \leq x_2 \\ 0 & \text{sinon} \end{cases}.$$

2. Les densités marginales de  $X_1$  et  $X_2$

# Distribution conditionnelle

- En analyse multi-variée, il est parfois nécessaire de connaître la distribution d'un vecteur aléatoire conditionnellement à un autre vecteur aléatoire. On parle alors de loi conditionnelle.

## Définition

La fonction de densité de probabilité conditionnelle de  $X_1, \dots, X_q$  sachant  $X_{q+1} = x_{q+1}, \dots, X_p = x_p$  est définie par

$$h(x_1, \dots, x_q | x_{q+1} \dots x_p) = \frac{f(x_1, \dots, x_p)}{g(x_{q+1}, \dots, x_p)},$$

où  $f(x_1, \dots, x_p)$  est la densité jointe de  $(X_1, \dots, X_p)$  et  $g(x_{q+1}, \dots, x_p)$  la densité jointe de  $(X_{q+1}, \dots, X_p)$ .

- Lorsque les variables aléatoires  $X_1, \dots, X_p$  sont indépendantes alors la densité conditionnelle coïncide avec la densité jointe de  $X_1, \dots, X_q$ .
- A partir de la densité conditionnelle on, définit la fonction de répartition conditionnelle par

$$F(x_1, \dots, x_q | x_{q+1} \dots x_p) = \frac{\int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_q} f(u_1, \dots, u_q, x_{q+1}, \dots, x_p) du_1 \dots, du_q}{g(x_{q+1}, \dots, x_p)}.$$

# Vecteurs gaussiens

## Définition

$\mathbf{X}$  est un vecteur Gaussien à  $p$  dimensions si toutes combinaisons linéaires de ses composantes suit une loi normale à une dimension.

## Remarque

La normalité de chacune des composantes de  $\mathbf{X}$  ne suffit pas à définir un vecteur gaussien.

Exemple :

$$\begin{pmatrix} X \\ -X \end{pmatrix} \text{ avec } X \sim \mathcal{N}(0, \sigma^2)$$

n'est pas un vecteur gaussien.

# Densité de probabilité de $\mathbf{X}$

## Théorème

Si  $\Sigma$  est régulière (déterminant non nul),  $\mathbf{X}$  admet pour densité :

$$f(x_1, x_2, \dots, x_p) = \frac{1}{(2\pi)^p (\det(\Sigma))^{1/2}} \exp \left( -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right)$$

## Remarque 1

La loi de  $\mathbf{X}$  est entièrement déterminée par la connaissance de son espérance  $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_p)^T$  et de sa matrice de variance covariance  $\Sigma$ . On notera

$$\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$$



## Remarque 2 : linéarité

Si  $\mathbf{X}$  est un vecteur gaussien de dimension  $p$ ,  $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$  et  $A$  une matrice à  $k$  lignes et  $p$  colonnes, et  $\mathbf{b}$  est un vecteur de dimension  $k$ , le vecteur  $A\mathbf{X} + \mathbf{b}$  est gaussien de dimension  $k$  et

$$A\mathbf{X} + \mathbf{b} \sim \mathcal{N}(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^T)$$

## Remarque 3

Si les composantes de  $\mathbf{X}$  sont décorrélées alors elles sont indépendantes. En effet, on remarque que si  $\Sigma = \sigma^2 \mathbf{I}_p$  alors

$$f(x_1, x_2, \dots, x_p) = \prod_{i=1}^p \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x_i - \mu_i)^2\right)$$

# Propriété de l'espérance conditionnelle

L'espérance conditionnelle de  $(Y, X_1, \dots, X_p)^T$  sachant  $X_1 = x_1, \dots, X_p = x_p$  est une fonction affine de  $x_1, \dots, x_p$ .  
En particulier

$$E(Y|X_1, \dots, X_p) = \sum_{i=1}^p a_i (X_i - E(X_i)) + E(Y)$$

avec

$$\begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{pmatrix} = V(X)^{-1} \begin{pmatrix} \text{cov}(Y, X_1) \\ \text{cov}(Y, X_2) \\ \vdots \\ \text{cov}(Y, X_p) \end{pmatrix}$$

# Loi du $\chi^2$

Soit  $X_1, \dots, X_n$ ,  $n$  v. a. gaussiennes indépendantes,  $X_i \sim \mathcal{N}(0, 1)$  pour tout  $i$ , alors la variable aléatoire  $V$  donnée par  $V = \sum_{i=1}^n X_i^2$  suit une loi du  $\chi^2$  à  $n$  degrés de libertés.

$$V = \sum_{i=1}^n X_i^2 \sim \chi_n^2$$

$$E(V) = n \quad V(V) = 2n$$