

## 1 KS d'adéquation

### Statistique de test

$$h(F_n, F) = \sup_{t \in \mathbb{R}} |F_n(t) - F(t)|$$

$$= \max_{1 \leq i \leq n} \left( \max \left( \left| \frac{i}{n} - F(X_{(i)}) \right|, \left| \frac{i-1}{n} - F(X_{(i)}) \right| \right) \right)$$

**Zone de Rejet** Si  $n$  est petit table Si  $n$  est grand  $n \geq 30$

$$\sqrt{nh_n} \rightarrow_{n \rightarrow \infty}^{\mathcal{L}} W_\infty.$$

$$\mathcal{R} = \{h(F_n, F_X) \geq \frac{k_\alpha}{\sqrt{n}}\}.$$

$k_\alpha$  le quantile de  $W_\infty$

**Méthode** Tableau avec  $i, X_{(i)}, F_0(X_{(i)}), \frac{i}{n}, |\frac{i}{n} - F_0(X_{(i)})|, |\frac{i-1}{n} - F_0(X_{(i)})|$

## 2 $\chi^2$ d'ajustement

**Conditions** Discret,  $n$  grand  $np_i \leq 5$

**Hypothèse**  $H_0 = p = p^{ref}$  VS  $H_1 = p \neq p^{ref}$

**Statistique de test**  $D(\bar{p}_n, p^{ref}) \sum_{k=1}^d \frac{(N_{k,n} - np_k^{ref})^2}{np_k^{ref}} \rightarrow_{n \rightarrow \infty}^{\mathcal{L}} \chi^2(d-1)$

$\chi^2(d-1)$

**Méthode** Tableau  $\bar{p}, p_i, np_i$  fusion des classes

**2.1  $\chi^2$  d'ajustement famille paramétrique** Comme avant mais  $\chi^2(d-1-M)$ ,  $M$  nombre de paramètre estimé.

## 3 KS d'homogénéité

**Conditions** Ech. indep.; fdr. continue  $F_X, F_Y$

**Hypothèse**  $H_0 : F_{X_1} = F_{Y_1}$  VS  $\neq$

**Statistique de test**  $\sup_{s \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq s} - \frac{1}{n} \sum_{j=1}^n \mathbb{1}_{Y_j \leq s} \right|$   $X_1$  et  $Y_1$  n'ont pas la même loi.

**Zone de Rejet** petit Table  $n$  grand

$$h_{n_1, n_2} = \sqrt{\frac{nm}{n+m}} h(F_n, G_n) \rightarrow_{n, m \rightarrow +\infty}^{\alpha} W_\infty \text{ voir KS asymptotique.}$$

zone de rejet  $\sqrt{\frac{n+m}{nm}} W_\infty$  avec  $W_\infty$  quantile  $W_\infty$ .

**Méthode** Même qu'un khi deux classique.  $Z_{(i)} = (X_i, Y_i) +$  tableau  $Z_{(i)}, F_n, G_n, h_{n_1, n_2}$

## 4 $\chi^2$ indépendance

**Donnée** Ech appariés. Discret.  $X$  dans  $M$  cas,  $Y$  dans  $N$  cas

**Conditions** Loi discrète.  $n$  grand  $E_{i,j} \leq 5$

**Hypothèse** Indépendance

**Statistique de test**  $D = \sum_{m=1}^M \sum_{n=1}^N \frac{(N_{m,n} - \frac{N_{m.} N_{.n}}{N})^2}{\frac{N_{m.} N_{.n}}{N}}$

**Zone de Rejet** Sous  $H_0, D \rightarrow \chi^2((M-1)(N-1))$ . Sous  $H_1, D \rightarrow +\infty$

**Méthode**

**5  $\chi^2$  d'homogénéité** Deux ech. indep. à valeurs dans les mêmes classes  $A_1, \dots, A_M$ . de vecteur loi

**Hypothèse** On veut tester l'homogénéité : même vecteur loi ou pas

## 6 Gaussiennes

### 6.1 Sur la moyenne

- Test sur 1 échantillon : Loi de Student
- Variance inconnu : On utilise  $\bar{X}_n$  dans  $V_n$
- Variance connu : on l'utilise à la place de  $V_n$

- Test sur 2 échantillons indépendants :
  - Variance inconnu : Test de welch :  $D = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2}}{\sqrt{\frac{V_{n_1}^X}{n_1} + \frac{V_{n_2}^Y}{n_2}}} \sim_{H_0} \mathcal{T}(\mu)$  avec  $\mu$

Formule horrible

- Même variance inconnu :  $\bar{X}_{n_1} - \bar{Y}_{n_2} \sim \mathcal{N}(m_1 - m_2, \sigma^2(\frac{1}{n_1} + \frac{1}{n_2}))$  Same stat de test sauf qu'on estime la variance avec  $W = \frac{(n_1-1)V_{n_1}^X + (n_2-1)V_{n_2}^Y}{n_1 + n_2 - 2}$ . Finalement la stat de test centrée réduite  $\sim \mathcal{T}(n_1 + n_2 - 2)$

— Variances connus :  $\bar{X}_{n_1} - \bar{Y}_{n_2} \sim \mathcal{N}(m_1 - m_2, \sigma^2(\frac{1}{n_1} + \frac{1}{n_2}))$  cette fois-ci de variance connus

- Test sur 2 échantillons appariés :  $Z_n = X_i - Y_i$  into  $\mathcal{T}(n-1)$  classique sur 1 échantillon (Y'a un exo de td il parait)

### 6.2 Sur la variance

- Test sur 1 échantillon : Comme le semestre d'avant
- Moyenne inconnu : On utilise  $\bar{X}_n$  dans le calcul de  $V_n$  puis penser que comme on connaît la moyenne ça suit une  $\chi^2(n)$
- Moyenne connu : On l'utilise dans le calcul de  $V_n$
- Test sur 2 échantillons indépendants :
  - Moyenne inconnu :  $D = \frac{V_{n_1}^X}{V_{n_2}^Y}$  qui suit  $\mathcal{F}(n_1 - 1, n_2 - 1)$  sans besoin de transformation.
  - Même Moyenne inconnu : X Pas de solution so do same as before
- Moyennes connus : L'utiliser dans les calcul des  $V_n$ . Est-ce qu'on gagne des degrés de liberté?
- Test sur 2 échantillons apparié : X (maybe un Zn into khi deux)

## 7 Somme des rangs

**Donnée** Deux ech. indep. de fdr. cont.

**Conditions** Continue; mieux que KS à 2 ech.

**Hypothèse**

- $H_0 = X_1$  et  $Y_1$  ont la même loi.  $F_{X_1} = F_{Y_1}$
- Ou  $X_1 \succ Y_1$  C'est à dire  $F_{X_1} \neq F_{Y_1}$  et  $\forall t \in \mathbb{R}, F_{X_1}(t) \leq F_{Y_1}(t)$
- Ou  $Y_1 \succ X_1$  C'est à dire  $F_{X_1} \neq F_{Y_1}$  et  $\forall t \in \mathbb{R}, F_{X_1}(t) \geq F_{Y_1}(t)$

**Statistique de test**  $U = \sum_{i=1}^{n_1} R(i)$  somme des rang des  $X_i$  ex-æquo rang moyen des rangs.

**Zone de Rejet** Utiliser symétrie.  $n$  grand TCL

**Méthode** tableau obs de différente couleur.

## 8 Signe

**Donnée** Deux ech. apparié. +  $Z_i = Y_i - X_i$  médiane  $m_Z$

**Conditions** Fonction de répartition continue. **Hypothèse**  $H_0 m_Z = 0$  VS  $H_1 = m_Z \neq 0$  ou autre possibilités

**Statistique de test**  $S_n = \sum_{i=1}^n \mathbb{1}_{Z_i \leq 0}$  = Nombre de  $Y_i > X_i$  d'ex-æquo = rang moyen des rangs

**Zone de Rejet**

- Sous  $H_0 : P(Z_i > 0) = P(Y_i > X_i) = \frac{1}{2} \Rightarrow S_n \sim \text{Bin}(n, \frac{1}{2})$
- Sous  $H_1$ 
  - Si  $m_Z > 0, P(Y_i > X_i) > \frac{1}{2}, S_n \sim \text{Bin}(n, p), p > \frac{1}{2}$  donc  $S_n$  est "grand"
  - Si  $m_Z < 0, P(Y_i < X_i) > \frac{1}{2}$  donc  $S_n$  est petit.
  - Si  $m_Z \neq 0, S_n$  a un comportement proche des extremes (petit/grand).

Table de la loi binomiale.  $n$  grand = TCL.

## 9 Signe et Rang

**Donnée** Deux ech. apparié.  $Z_i = Y_i - X_i$  iid. de médiane  $m$

**Conditions** La loi des  $Z_i$  est continue. Les  $Z_i$  sont symétriques par rapport à leur médiane  $m$ .

**Hypothèse**  $H_0 = m = 0 \Leftrightarrow P(Y_i > X_i) = P(X_i < Y_i) = \frac{1}{2}$  VS  $H_0 = m \neq 0$  ou  $m > 0$  ou  $m < 0$

**Statistique de test** Somme des rangs positif (ou négatif) des  $Z_{(i)}$

**Zone de Rejet**

- Sous  $H_0, W_n^+ \sim \mathcal{B}(n, \frac{1}{2})$
- Sous  $H_1$

—  $H_1 : m > 0 \Leftrightarrow X_i > Y_i \Leftrightarrow$  plus de rang positif  $\Leftrightarrow W_n^+$  prend de plus grande valeur et  $W_n^-$  de plus petite.

—  $H_1 : m > 0$  Même raisonnement

—  $H_1 : m \neq 0 \Leftrightarrow W_n^+$  prend des valeurs extremes.

Bref on regarde la table avec le  $n$  nombre de couple  $(X_i, Y_i)$ . On fait attention si on regarde  $W_n^+$  ou  $W_n^-$ . Et on utilise la symétrie avec les formules du centre ou des extrémités pour trouver l'autre quantile si besoin.

**Méthode** tableau  $X_{(i)}, Y_{(i)}, Z_i, Z_{(i)}, \text{Rang}$

## 10 Indépendance Pearson

**Donnée** Deux ech. apparié  $\mathcal{N}(m, \sigma^2)$

**Conditions** Gaussien car c'est ce qui crée l'équivalence entre corrélation et indépendance

**Hypothèse** indépendance  $\Leftrightarrow Cor = 0$

**Statistique de test** Soit  $R$  la corrélation empirique :

$$R = \frac{\text{cov}_n((X_1, \dots, X_n), (Y_1, \dots, Y_n))}{\sqrt{V_n^X * V_n^Y}}$$

$$R_n = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n)}{\sqrt{(\sum_{i=1}^n (X_i - \bar{X}_n)^2) (\sum_{i=1}^n (Y_i - \bar{Y}_n)^2)}}$$

$$D = \frac{R_n}{\sqrt{1 - R_n^2}} \sqrt{n-1}.$$

**Zone de Rejet** Sous  $H_0, D \sim \mathcal{T}(n-2)$ . Sous  $H_1, D$  est grand en valeur absolue

## 11 Comparaison asymptotique de proportion

**Donnée** Deux ech. indep.  $\text{Ber}(p_1 \text{ ou } p_2)$

**Conditions** Bernouilli + Ech indépendant

**Hypothèse**  $H_0 = p_1 = p_2$  VS  $H_1 = p_1 \neq p_2$  ou  $p_1 < p_2$  ou  $p_1 > p_2$

**Statistique de test**  $S_{n,m} = \frac{\bar{X}_n - \bar{Y}_n}{\sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n} + \frac{\bar{Y}_n(1-\bar{Y}_n)}{n}}}$

**Zone de Rejet**

- Sous  $H_0, S_{n,m} \rightarrow_{n, m \rightarrow +\infty}^{\mathcal{L}} \mathcal{N}(0, 1)$
- Sous  $H_1$ 
  - Si  $p_1 > p_2, S_{n,m} \rightarrow_{n, m \rightarrow +\infty} +\infty$
  - Si  $p_1 < p_2, S_{n,m} \rightarrow_{n, m \rightarrow +\infty} -\infty$
  - Si  $p_1 \neq p_2, S_{n,m} \rightarrow_{n, m \rightarrow +\infty} \pm\infty$

Donc

- $H_1 : p_1 > p_2, \mathcal{R} = \{S > h_{1-\alpha}\}$
- $H_1 : p_1 < p_2, \mathcal{R} = \{S < h_\alpha\}$
- $H_1 : p_1 \neq p_2, \mathcal{R} = \{S > h_{\alpha/2}\} \cup \{S < h_{1-\alpha/2}\}$

Où les  $h_\alpha$  sont des quantiles de la loi normale.

## 12 ANOVA

**Donnée**  $K$  ech. gaussien de même variance

**Conditions** Échantillon gaussien indep., homoscedasticité :  $\sigma_1^2 = \dots = \sigma_K^2$

**Hypothèse** égalité ou non des moyennes

**Statistique de test**  $SCE_{intra}^{totale} = \sum_{p=1}^K SCE^{(p)}$

$\bar{X}$  = moyenne totale =  $\frac{1}{n} \sum_{p=1}^K n_p \bar{X}^{(p)}$

$SCE_{inter} = \sum_{p=1}^K n_p (\bar{X}^{(p)} - \bar{X})^2$

**Zone de Rejet**  $F = \frac{SCE_{inter}/(K-1)}{SCE_{intra}^{totale}/(n-K)}$  Sous

$H_0 : F \sim \mathcal{F}(K-1, n-K)$ . Sous  $H_1, F$  prend de grande valeurs.

**Méthode** Tout calculer jusqu'à la stat de test.

- Si la loi de Fisher est trop grande. On se souvient que

$$\frac{\chi^2(k)}{k} \rightarrow_{k \rightarrow +\infty} 1$$

$$\Rightarrow F = \frac{SCE_{inter}/(K-1)}{SCE_{intra}^{totale}/(n-K)} \rightarrow \frac{SCE_{inter}/(K-1)}{1} = \chi^2(K-1)/K-1$$

- Si on ne nous donne pas SCE directement on sait que

$$SCE^{(p)} = \sum_{i=1}^{n_p} (X_i^{(p)} - \bar{X}^{(p)})^2 = (n_p - 1) V^{(p)}.$$