

Statistiques décisionnelles : TD 1

- Exercice 1.**
1. Vous vous promenez le long d'une voie ferrée, en pleine rêverie. Vous prenez soudain conscience d'un grand bruit, droit derrière vous. En quoi consiste l'erreur de première espèce ? L'erreur de deuxième espèce ? Laquelle est la plus grave ? Que faites-vous ?
 2. Vrai ou faux : si on compare un test d'hypothèses à un jugement, on peut dire que l'erreur de première espèce est de condamner un homme coupable.
 3. Dans l'analogie du jugement, que se passerait-il, si on souhaitait rendre l'erreur de première espèce nulle ?
 4. Dans l'analogie du jugement, comment interpréter la puissance du test ?

Définition 1. Si X_1, \dots, X_n sont des variables aléatoires, on note $X_{(1)}, \dots, X_{(n)}$ l'échantillon ordonné croissant des X_i . Ainsi, $X_{(1)}$ est la plus petite valeur prise par les X_i , $X_{(2)}$ la seconde plus petite valeur et ainsi de suite jusqu'à $X_{(n)}$ qui est la plus grande valeur des X_i . Cette notation avec des parenthèses est standard en probabilités et statistiques. Attention, les X_i sont i.i.d. mais les $X_{(i)}$ ne sont ni indépendants, ni identiquement distribués. Gardez en tête que $X_{(i)}$ dépend de toutes les variables X_1, \dots, X_n .

Exercice 2 (Rappels sur les fonctions de répartition). Soit $(X_i)_{i \in \mathbb{N}^*}$ une suite de variables aléatoires i.i.d. de loi inconnue.

1. Rappeler la définition de la fonction de répartition des X_i , notée F_X , ainsi que la fonction de répartition empirique, notée F_n .
2. Représenter graphiquement F_X et F_n lorsque les X_i suivent une loi uniforme sur $[0, 1]$ et où on a obtenu les valeurs

$$X_1 = 0.17 \quad X_2 = 0.66 \quad X_3 = 0.42 \quad X_4 = 0.62, \quad X_5 = 0.41.$$

Sur ce graphe, que vaut $\sup |F_X(t) - F_n(t)|$?

3. Représenter graphiquement F_X et F_n lorsque les X_i suivent une loi $\mathcal{E}(1)$ et où on a obtenu les valeurs

$$X_1 = 0.33 \quad X_2 = 0.98 \quad X_3 = 0.53 \quad X_4 = 0.22, \quad X_5 = 0.39.$$

Sur ce graphe, que vaut $\sup |F_X(t) - F_n(t)|$?

4. Montrer que, quel que soit $t \in \mathbb{R}$, la suite $(F_n(t))_{n \geq 1}$ converge presque sûrement vers $F_X(t)$.
5. Donner un intervalle de confiance asymptotique pour $F_X(t)$ de niveau 95%.
6. Rappeler le théorème de Glivenko-Cantelli. Quelle est la différence avec ce qui a été montré précédemment ? Comment calculez-vous en pratique $\sup_{t \in \mathbb{R}} |F_X(t) - F_n(t)|$? On pourra ordonner les variables X_i de manière croissante en notant $X_{(i)}$ la i -ème plus grande valeur dans l'échantillon X_1, \dots, X_n .

Exercice 3. Soit X_1, \dots, X_n un échantillon i.i.d. de loi $\mathcal{E}(\lambda)$.

1. Si U est une variable aléatoire de loi uniforme sur $[0, 1]$, calculer la fonction de répartition de $-\ln(1-U)$ et en déduire la loi de cette variable. Quel théorème du cours est illustré ici ?
2. Si X est une variable aléatoire de loi $\mathcal{E}(1)$, quelle est la loi de $\frac{1}{\lambda}X$? En déduire la loi de $-\frac{1}{\lambda}\ln(1-U)$ si U est une variable aléatoire de loi uniforme sur $[0, 1]$.
3. Si X est une variable aléatoire de loi $\mathcal{E}(1)$, quelle est la loi de $1 - e^{-X}$?
Bonus : Si F_X est inversible, quelle est la loi de $F_X(X)$?
4. Soient U_1, \dots, U_n des variables aléatoires i.i.d. uniformes sur $[0, 1]$. On définit les Y_i par $Y_i = -\frac{1}{\lambda}\ln(1 - U_i)$. Quelle est la relation entre les variables ordonnées $Y_{(1)}, \dots, Y_{(n)}$ et $U_{(1)}, \dots, U_{(n)}$?
5. Pour différentes valeurs de n , on cherche à comprendre la loi de la variable aléatoire $\sup_{t \in \mathbb{R}} |F_X(t) - F_n(t)|$. En vous inspirant de l'exercice précédent, écrivez cette quantité comme un maximum d'un nombre fini de quantités mettant en jeu les $X_{(i)}$
6. Si X suit une loi exponentielle de paramètre 1 et $n = 1$, explicitiez la variable aléatoire $\sup_{t \in \mathbb{R}} |F_X(t) - F_n(t)|$. Même question si X suit une loi exponentielle de paramètre λ .
7. Même question si U suit une loi uniforme sur $[0, 1]$.
8. Même question si $Y = -\frac{1}{\lambda}\ln(1 - U)$ où U suit une loi uniforme sur $[0, 1]$.
Que remarquez-vous ? Reliez cette question aux deux précédentes.
9. Recommencez la question précédente pour $n = 2$ puis n quelconque. Après réflexion, de quoi dépend la variable $\sup_{t \in \mathbb{R}} |F_X(t) - F_n(t)|$?
10. Comment feriez-vous pour connaître approximativement les propriétés de cette variable pour $n = 1$, $n = 5$? (à l'aide d'un ordinateur et de R).