

## Statistiques décisionnelles : TD 5

Pour effectuer le test d'homogénéité de Kolmogorov-Smirnov, on utilisera  $\text{ks.test}(X, Y)$  où  $X$  et  $Y$  sont des vecteurs contenant les observations. Attention, si vous faites  $\text{ks.test}(X, "F")$  où  $X$  est un vecteur et  $F$  est une fonction, vous effectuerez un test d'ajustement de Kolmogorov-Smirnov.

**Exercice 1.** On mesure les temps de course au 80 mètres de deux groupes d'athlètes français et belges. Les temps mesurés sont donnés ci-dessous :

**français :** 9.07 9.06 10.7 9.56 10.46 9.3 9.08 11.94 12.28 9.84

**belges :** 10.52 9.6 11.0 10.67 12.24 10.86 9.74.

Ces deux groupes sont-ils homogènes, au niveau 5% ?

**Exercice 2.** On a mesuré les températures moyennes en Janvier tous les ans à Lille entre 2000 et 2010 et à Zurich entre 2011 et 2020. Toutes les données sont réelles.

**Lille :** 4.2 3.6 4.1 4 5.3 2 7.4 6.5 0.7 0.2

**Zurich :** 1.2 2 0.6 3.2 1.9 2.8 -3 4.7 0.1 2.6.

Ces deux groupes sont-ils homogènes, au niveau 0.05 ? Quand vous aurez traité l'exercice 4, vous pourrez refaire cet exercice en vous demandant s'il fait meilleur en janvier à Lille ou à Zurich.

**Exercice 3.** On a mesuré la vitesse moyenne du vent toutes les semaines pendant les deux derniers mois au cap blanc nez et au cap gris nez, exprimé en  $\text{km.h}^{-1}$

**Blanc-nez :** 34 49 2.7 53 81 61 41 150

**Gris-nez :** 40 52 5 47 90 64 39 173

Peut-on dire que ces relevés ont la même loi ?

**Exercice 4** (Test d'homogénéité Kolmogorov-Smirnov unilatéral ou « one sided »). Le but de cet exercice est d'introduire une variante du test d'homogénéité de Kolmogorov-Smirnov avec une hypothèse alternative différente de celle vue en cours. Pour deux variables aléatoires  $X$  et  $Y$ , on dit que  $Y$  domine  $X$  si  $\forall t \in \mathbb{R}, F_Y(t) \leq F_X(t)$ . On le note  $Y \succ X$ . Cela signifie que  $Y$  a tendance à prendre des valeurs plus grandes que  $X$ . Cela ne veut pas dire que  $Y$  prend toujours des valeurs plus grandes que  $X$  ! Les questions ci-dessous ont pour but de vous familiariser avec cette notion.

1. Montrer que si  $X$  est uniforme sur  $[0, 1]$  et  $Y$  uniforme sur  $[2, 3]$ , alors  $Y \succ X$ .
2. Montrer que si  $X$  est uniforme sur  $[0, 1]$  et  $Y$  est uniforme sur  $[0, 2]$  alors  $Y \succ X$ .
3. Montrer que si  $X$  est uniforme sur  $[0, 1[$  et  $Y \sim \mathcal{N}(0, 1)$  alors  $Y$  ne domine pas  $X$ , et  $X$  ne domine pas  $Y$ .

Cette notion de domination est utile pour comparer deux variables aléatoires en statistiques. Par exemple, si on teste l'efficacité d'un médicament, on peut vouloir prendre  $H_0$  "le médicament ne fait pas d'effet" contre  $H_1$  "le médicament a un effet positif" (l'hypothèse usuelle serait "le médicament a un effet").

On dispose de deux échantillons indépendants des variables i.i.d.  $(X_1, \dots, X_n)$  et  $(Y_1, \dots, Y_m)$ . On cherche à construire un test pour :

- $H_0$  :  $X_1$  et  $Y_1$  ont même loi, c'est à dire  $F_{X_1} = F_{Y_1}$ .
- $H_1$  :  $X_1$  et  $Y_1$  n'ont pas la même loi, et  $Y_1 \succ X_1$ .

On introduit la statistique de test

$$T_{n,m} = \sup_{t \in \mathbb{R}} F_n(t) - G_m(t)$$

où  $F_n$  est la fonction de répartition empirique des  $X_i$  et  $G_m$  est la fonction de répartition empirique des  $Y_j$ .

Les questions suivantes ont pour but de vous aider à vous poser quelques questions sur cette statistique de test, j'attends de vous que vous compariez cette statistique de test au test d'homogénéité de Kolmogorov-Smirnov fait en cours pour vous familiariser avec ces deux objets.

4. Sous  $H_0$ , la loi de  $T_{n,m}$  dépend-elle de la loi des  $X_i$  ?
5. Sous  $H_1$ , si  $n$  et  $m$  tendent vers l'infini, quelle est la limite de  $T_{n,m}$  ? Quel est son signe ?
6. Construire un test de niveau  $\alpha$  pour le test de  $H_0$  contre  $H_1$ .

**Application :** On teste l'effet d'un somnifère sur deux groupes indépendants de 11 personnes. Le groupe contrôle a reçu un produit inactif (I), alors que le groupe test a reçu le somnifère (S). Les temps de sommeil moyens pour ces individus, exprimés en minutes, sont présentés dans le tableau ci-dessous.

S	560	470	580	570	550	485	460	540	620	550	620
I	590	530	435	360	430	570	490	480	380	400	350

Si on note  $X_i$  les durées de sommeil du groupe contrôle et  $Y_i$  les durées de sommeil du groupe test, traduire l'efficacité du somnifère en terme de domination de variables aléatoires. Déterminer si, au niveau 5%, ce produit est efficace.

**Super Bonus :** Construisez une variante du test d'ajustement de Kolmogorov-Smirnov pour un échantillon i.i.d.  $X_1, \dots, X_n$  et une fonction de répartition cible  $F$  et les hypothèses  $H_0 : F_{X_1} = F$  et  $H_1 : F_{X_1} \neq F$  et  $F_{X_1} \leq F$ .

**Exercice 5.** Neufs parcelles ont été cultivées dans une région A et sept parcelles dans une région B. On vous donne les rendements constatés :

Région A : 48,0 48,2 50,3 53,5 54,6 56,4 57,8 58,5 60,5.  
Région B : 44,2 46,3 48,3 48,5 50,5 51,2 55,4.

1. Les deux régions sont-elles aussi fertiles ?
2. La région A est-elle plus fertile que la B ?