

Liste des Tests du cours

Charles Vin

2022

Table des matières

| | | |
|-----------|--|-----------|
| 1 | Template | 2 |
| 2 | Test d'ajustement de Kolmogorov-Smirnov | 2 |
| 3 | Le test du χ^2 d'ajustement | 3 |
| 3.1 | Le χ^2 d'ajustement à une famille paramétrique de loi | 4 |
| 4 | Le test d'homogénéité de Kolmogorov-Smirnov | 4 |
| 5 | Test du χ^2 d'indépendance | 5 |
| 6 | Test du χ^2 d'homogénéité | 6 |
| 7 | Test sur les Gaussiennes | 7 |
| 7.1 | Sur la moyenne | 7 |
| 7.2 | Sur la variance | 7 |
| 8 | Test de la somme des rangs | 7 |
| 9 | Test du signe | 8 |
| 10 | Signe et Rang | 10 |
| 11 | Test d'indépendance de Pearson | 10 |
| 12 | Test de comparaison asymptotique de proportion | 10 |
| 13 | ANOVA | 10 |

| | | |
|---|--|---|
| | | Echantillon appariés |
| Peu de données On test si la médiane est nulle Wilcoxon somme des rangs (Mann Witney) (va cont.) (comparaison de médiane) | | Test du signe; Test de Wilcoxon si KS d'homogénéité (comparaison d |
| Beaucoup de données | | Espérance de la différence null? (T |
| Données Gaussiennes Welsh (ss hypo sur variance) comparaison des espérances | | Student de la différence (test si l'es |

| | | |
|--|---------------------------|---------------------------------------|
| (X_i, Y_i) | Discret | Continue |
| Discret | χ^2 (si bcp de data) | |
| Continue | KS (si 2 modalités) | Test de corrélation (gaussienne ou bo |
| Spearman ou Kendall (peu de données, non gaussienne) | | |

1 Template

Donnée

Conditions

Hypothèse

Statistique de test

Zone de Rejet

Méthode

2 Test d'ajustement de Kolmogorov-Smirnov

Conditions

1. Les X_i semblent provenir d'une loi à fonction de répartition continue. \Rightarrow on n'a pas plusieurs fois la même valeur (sauf si celle-ci on était arrondi).
2. Fonctionne $\forall n$: même si n est petit, ce test est pertinent
3. Si $n \geq 100$, on fait un test asymptotique.

Hypothèse

- H_0 = les X_i ont pour fdr. F_X
- H_1 = les X_i n'ont pas pour fdr. F_X

Statistique de test

$$h(F_n, F) = \sup_{t \in \mathbb{R}} |F_n(t) - F(t)|$$

$$= \max_{1 \leq i \leq n} \left(\max \left(\left| \frac{i}{n} - F(X_{(i)}) \right|, \left| \frac{i-1}{n} - F(X_{(i)}) \right| \right) \right)$$

Zone de Rejet

Si n est petit

La loi de $h(F_n, F)$ est tabulé alors :

$$\mathcal{R} = \{h(F_n, F_X) \geq h_{1-\alpha}\}.$$

avec F_n fonction de répartition empirique, $h_{1-\alpha}$ le quantile à aller chercher dans la table

Si n est grand $n \geq 30$

Attention pas souvenir de l'avoir fait en TD.
On a pas la table de $h(F_n, F)$ mais on sait que

$$\sqrt{n}h_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} W_\infty.$$

Donc on pose la zone de rejet

$$\mathcal{R} = \{h(F_n, F_X) \geq \frac{k_\alpha}{\sqrt{n}}\}.$$

avec F_n fonction de réparation empirique, k_α le quantile de W_∞ à aller chercher dans sa table

Méthode

Pour trouver la valeur de $h(F_n, F_X)$: Faire le grand tableau puis trouver le max. Exemple :

| i | 1 | 2 | 3 | 4 | 5 |
|----------------------------------|-------|-------|-------|-------|-------|
| $X_{(i)}$ | 0.3 | 0.7 | 0.9 | 1.2 | 1.4 |
| $X_{(i)} - 2$ | -1.70 | -1.30 | -1.10 | -0.80 | -0.60 |
| $F_0(X_{(i)})$ | 0.04 | 0.10 | 0.14 | 0.21 | 0.27 |
| $\frac{i}{n}$ | 0.05 | 0.1 | 0.15 | 0.2 | 0.25 |
| $ \frac{i}{n} - F_0(X_{(i)}) $ | 0.01 | 0.00 | 0.01 | 0.01 | 0.02 |
| $ \frac{i-1}{n} - F_0(X_{(i)}) $ | 0.04 | 0.05 | 0.04 | 0.06 | 0.07 |

Table 1 – Ici le max c'est 0.07 à la dernière case

3 Le test du χ^2 d'ajustement

Conditions

1. Les X_i sont à valeur dans un ensemble fini (loi discrète). Si a valeur dans \mathbb{N} , on fusionne les classes à partir d'un certain rang choisis
2. Test asymptotique : $\forall k \in \{1, \dots, d\}, np_k^{ref} (1 - p_k^{ref}) \geq 5 \Leftrightarrow n \geq 20$

Si on ne remplit pas les conditions, on peut fusionner les classes

Hypothèse

$$H_0 = p = p^{ref} \text{ i.e. } \forall k \in \{1, \dots, d\}, p_k = p_k^{ref}$$

$$H_1 = p \neq p^{ref} \text{ i.e. } \exists k \in \{1, \dots, d\} : p_k \neq p_k^{ref}$$

Avec p^{ref} un vecteur fixé à tester (par exemple pour un lancé de dé $(\frac{1}{6}, \dots, \frac{1}{6})$)

Statistique de test

$$\begin{aligned} D(\bar{p}_n, p^{ref}) &= n \sum_{k=1}^d \frac{(p_{k,n} - p_k^{ref})^2}{p_k^{ref}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \chi^2(d-1) \\ &= \sum_{k=1}^d \frac{(N_{k,n} - np_k^{ref})^2}{np_k^{ref}} \end{aligned}$$

avec

- $N_{k,n} = \sum_{i=1}^n \mathbb{1}_{X_i = x_k}$ (ce qu'il y a dans le tableau de la consigne)
- $p_{k,n} = \frac{N_{k,n}}{n}$ les proportions observés

Zone de Rejet

$$\mathcal{R} = \{D(\bar{p}_n, p^{ref}) \geq h_\alpha\}.$$

avec h_α le quantile d'ordre $1 - \alpha$ de la loi $\mathcal{X}^2(d - 1)$

Méthode

1. Etape 0 : On vérifie les conditions

$$\forall k \in \{1, \dots, d\}, n * p_k \geq 5.$$

C'est la condition de Cochran (1954), il avait testé cas possible en observant l'approximation faites.

2. Etape 1 : On calcule les effectifs et proportions observées : $N_{k,n}$ et $\hat{p}_{k,n}$

3. Etape 2 : Calcul de la statistique de test

$$D = n \sum_d^{k=1} \frac{(\hat{p}_{k,n} - p_k)^2}{p_k}.$$

4. Etape 3 : Détermination de la zone de rejet au niveau α . On lit h_α le quantile d'ordre $1 - \alpha$ de la loi $\mathcal{X}^2(d_1)$
5. Etape 4 : Décisions
 - si $D > h_\alpha$, on rejette H_0 (au niveau α).
 - Si $D \leq h_\alpha$ on conserve H_0

Bilan de la méthode

Aspects positifs :

- **Fonctionne pour toutes les lois**
- Facile à faire

Aspects négatifs :

- Problème de consistance. Regrouper les variables par intervalle ruiner l'erreur de seconde espèce.
- Asymptotique
- Dépendant du choix des intervalles. Ce qui n'est pas canonique.

3.1 Le \mathcal{X}^2 d'ajustement à une famille paramétrique de loi

Pratiquement comme avant, pas encore fait en TD, mais copier collé du cours quand même

1. Etape 1 : Soit $\hat{\theta}_n$ l'estimateur du maximum de vraisemblance de θ (pour P_θ). On estime **tous** les paramètres de la loi ($p_1^{\hat{\theta}_n}, \dots, p_d^{\hat{\theta}_n}$)
2. Etape 2 : On vas tester l'ajustement de X_1, \dots, X_n à $P_{\hat{\theta}_n}$. On calcule les fréquences observées $\hat{p}_{k,n}$.
3. Etape 3 : Vérification des conditions $np_k^{\hat{\theta}_n}$ et possible regroupement en classes
4. Etape 4 : Calcul de la stat de test D
5. Etape 5 : Zone de rejet : lecture de H_α le quantile d'ordre $1 - \alpha$ d'une $\mathcal{X}^2(d - 1 - M)$ avec M nombre de paramètre.
6. Etape 6 : Décision
 - $D > h_\alpha$ on rejette H_0
 - $D \leq h_\alpha$ on conserve H_0

4 Le test d'homogénéité de Kolmogorov-Smirnov

Conditions

- Deux échantillons indépendants de variable iid.
- De fdr. continue F_X, F_Y

| $Z_{(i)}$ | F_n | G_n | h_{n_1, n_2} |
|-----------|-------|-------|----------------|
| ... | ... | ... | ... |

Hypothèse

- H_0 : les X_i et Y_i ont la même loi, c'est à dire $F_{X_1} = F_{Y_1}$ où F_{X_1}, F_{Y_1} sont continues.
- H_1 les lois sont différentes

Statistique de test

$$\sup_{s \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq s} - \frac{1}{n} \sum_{j=1}^n \mathbb{1}_{Y_j \leq s} \right|.$$

Zone de Rejet

- Ce test est de taille α , si on utilise la table de $h_{n,m} = \sup_{s \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - \frac{1}{n} \sum_{j=1}^n \mathbb{1}_{V_j \leq s} \right|$.
- Si n et m sont trop grands, on utilise le résultat suivant :
Sous H_0

$$h_{n_1, n_2} = \sqrt{\frac{nm}{n+m}} h(F_n, G_n) \xrightarrow[n, m \rightarrow +\infty]{\alpha} W_\infty \text{ voir KS asymptotique.}$$

On utilise alors comme zone de rejet $\sqrt{\frac{n+m}{nm}} W_\infty$ avec W_∞ le quantile d'ordre $1 - \alpha$ de W_∞ .

Méthode

Même qu'un khi deux classique!

$$Z_{(i)} = (X_i, Y_i)$$

5 Test du χ^2 d'indépendance

Donnée

- $(X_1, Y_1), \dots, (X_T, Y_T)$ iid appariés.
- X_1 à valeur dans A_1, \dots, A_M
 - Y_1 à valeur dans B_1, \dots, B_N

Conditions

- Loi discrète
- n ou T plutôt grand
- $\forall i < M, j < N : T * \hat{p}_m \hat{q}_m \geq 5$ ou avec la notation en TD : $E_{i,j} \geq 5$

Hypothèse

- $H_0 : X_1 \perp Y_1$
- $H_1 : X_1 \not\perp Y_1$

Statistique de test

$$D = T * \sum_{m=1}^M \sum_{n=1}^N \frac{(\hat{p}_{m,n} - \hat{p}_m \hat{q}_n)^2}{\hat{p}_m \hat{q}_n}$$

$$= \sum_{m=1}^M \sum_{n=1}^N \frac{(N_{m,n} - \frac{N_{m,.} N_{.,n}}{T})^2}{\frac{N_{m,.} N_{.,n}}{T}}$$

On utilise la deuxième en TD, la fraction est équivalent à $E_{i,j}$ aka le produit en croix à l'intérieur du tableau durant les TD (groupe 2)

Zone de Rejet

- Sous H_0 , $D \rightarrow \chi^2((M-1)(N-1))$
- Sous H_1 , $D \rightarrow +\infty$

$$\mathcal{R} = \{D \geq h_\alpha\}.$$

Méthode

$$E_{1,1} * 1000 = 152 * 261$$

$$\Leftrightarrow E_{1,1} = \frac{152 * 261}{1000} = 128.67$$

| yeux \ cheveux | Noirs (A_1) | Bruns | Blonds | Roux | Total |
|-------------------|-----------------|-----------------|--------|------|-----------------|
| Marrons (B_1) | $N_{1,1} = 152$ | $N_{2,1} = 247$ | 83 | 11 | $N_{.,1} = 152$ |
| Vert ou Gris | 73 | 114 | 37 | 8 | 232 |
| Bleus | 36 | 167 | 127 | 10 | 275 |
| Total | $N_{1,.} = 261$ | 463 | 247 | 29 | 1000 |

| yeux \ cheveux | Noirs (A_1) | Bruns | Blonds | Roux | Total |
|-------------------|-----------------|--------|--------|------|-----------------|
| Marrons (B_1) | 128.67 | 228.26 | 121.77 | 14.3 | $N_{.,1} = 152$ |
| Vert ou Gris | 60.55 | 107.42 | 57.3 | 6.73 | 232 |
| Bleus | 71.78 | 127.32 | 67.93 | 7.98 | 275 |
| Total | $N_{1,.} = 261$ | 463 | 247 | 29 | 1000 |

Puis calculer la stat de test

$$D = \sum_{\text{chaque case du tableau}} \frac{N_{1,1} - E_{1,1}}{E_{1,1}}.$$

6 Test du χ^2 d'homogénéité

Donnée

- X_1, \dots, X_{n_1} échantillons iid
- Y_1, \dots, Y_{n_2} échantillons iid
- Échantillons indépendant entre eux

Les variables sont toutes à valeurs dans les mêmes classes A_1, \dots, A_M .

Conditions

Hypothèse

On veut tester l'homogénéité

- $H_0 = X_1$ et Y_1 ont la même loi $\Leftrightarrow \forall m \in \{1, \dots, M\}, P(X_1 \in A_m) = P(Y_1 \in A_m)$
- $H_1 = X_1$ et Y_1 n'ont pas la même loi $\Leftrightarrow \exists m \in \{1, \dots, M\}$ tel que $P(X_1 \in A_m) \neq P(Y_1 \in A_m)$

Statistique de test

Zone de Rejet

Méthode

7 Test sur les Gaussiennes

7.1 Sur la moyenne

- Test sur 1 échantillon : Loi de Student
 - Variance inconnu : On utilise \bar{X}_n dans V_n
 - Variance connu : on l'utilise à la place de V_n
- Test sur 2 échantillons indépendants :
 - Variance inconnu : Test de welch : $D = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2}}{\sqrt{\frac{V_{n_1}^X}{n_1} + \frac{V_{n_2}^Y}{n_2}}} \sim_{H_0} \mathcal{T}(\mu)$ avec μ Formule horrible
 - Même variance inconnu : $\bar{X}_{n_1} - \bar{Y}_{n_2} \sim \mathcal{N}(m_1 - m_2, \sigma^2(\frac{1}{n_1} + \frac{1}{n_2}))$ Same stat de test sauf qu'on estime la variance avec $W = \frac{(n_1-1)V_{n_1}^X + (n_2-1)V_{n_2}^Y}{n_1 + n_2 - 2}$. Finalement la stat de test centrée réduite $\sim \mathcal{T}(n_1 + n_2 - 2)$
 - Variances connus : $\bar{X}_{n_1} - \bar{Y}_{n_2} \sim \mathcal{N}(m_1 - m_2, \sigma^2(\frac{1}{n_1} + \frac{1}{n_2}))$ cette fois-ci de variance connus
- Test sur 2 échantillons appariés : $Z_n = X_i - Y_i$ into $\mathcal{T}(n_1)$ classique sur 1 échantillon (Y'a un exo de td il paraît)

7.2 Sur la variance

- Test sur 1 échantillon : Comme le semestre d'avant
 - Moyenne inconnu : On utilise \bar{X}_n dans le calcul de V_n puis penser que comme on connaît la moyenne ça suit une $\chi^2(n)$
 - Moyenne connu : On l'utilise dans le calcul de V_n
- Test sur 2 échantillons indépendants :
 - Moyenne inconnu : $D = \frac{V_{n_1}^X}{V_{n_2}^Y}$ qui suit $\mathcal{F}(n_1 - 1, n_2 - 1)$ sans besoin de transformation.
 - Même Moyenne inconnu : X Pas de solution so do same as before
 - Moyennes connus : L'utiliser dans les calcul des V_n . Est-ce qu'on gagne des degrés de liberté?
- Test sur 2 échantillons apparié : X (maybe un Zn into khi deux)

8 Test de la somme des rangs

C'est le test de sur l'ordre stochastique.

Donnée

- X_1, \dots, X_{n_1} iid.
- Y_1, \dots, Y_{n_2} iid.
- Échantillons indépendants
- On suppose que F_X et F_Y sont **continues**.

Conditions

- On suppose que F_X et F_Y sont **continues**.
- Mieux qu'un KS à deux échantillons!

Hypothèse

- $H_0 = X_1$ et Y_1 ont la même loi. $F_{X_1} = F_{Y_1}$
- $H_0 = X_1$ et Y_1 n'ont pas la même loi. $F_{X_1} \neq F_{Y_1}$
 - Ou $X_1 \succ Y_1$ C'est à dire $F_{X_1} \neq F_{Y_1}$ et $\forall t \in \mathbb{R}, F_{Y_1}(t) \leq F_{X_1}(t)$

— Ou $Y_1 \succ X_1$ C'est à dire $F_{X_1} \neq F_{Y_1}$ et $\forall t \in \mathbb{R}, F_{X_1}(t) \leq F_{Y_1}(t)$

Statistique de test

$$U = \sum_{i=1}^{n_1} R(i) = \sum_{i=1}^{n_1} \sum_{j=1}^n \mathbb{1}_{X_i \leq Z_j}.$$

Remarque. En cas d'ex-æquo, on leur attribue le rang moyen des rangs. Voir exemple.

Zone de Rejet

La loi est symétrique. On a uniquement la table d'un côté, il faut calculer l'autre coté $h_{1-\alpha} = h_\alpha + 2\left(\frac{n_1 n_2 + 1}{2} - h_\alpha\right) =$.

Si n est grand, on utilise le TCL suivant

$$\frac{U - E(U)}{\sqrt{Var(U)}} = \frac{U - n \frac{n_1 + 1}{2}}{\sqrt{\frac{n_1 n_2 (n_1 + 1)}{12}}} \rightarrow Z \sim \mathcal{N}(0, 1).$$

Méthode

On trie les données : On calcule

| | | | | | | | | | |
|------|------------|-----------|-------------|------|-------------|------|-------------|-------------|-------------|
| Obs | 5.6 | 7.4 | 9.6 | 11 | 12.6 | 12.6 | 12.8 | 13 | |
| Rang | 1 | 2 | 3 | 4 | 5.5 | 5.5 | 7 | 8 | |
| Obs | 14.8 | 15 | 15.2 | 15.4 | 15.6 | 15.6 | 16.4 | 16.4 | 18.8 |
| Rang | 9 | 10 | 11 | 12 | 13.5 | 13.5 | 15.5 | 15.5 | 17 |

$$U = 1 + 7 + 10 + 11 + 13.5 + 15.5 + 15.5 + 17 \\ = \text{Somme des rangs de } X_i = 90.5$$

9 Test du signe

Donnée

- X_1, \dots, X_{n_1} iid.
- Y_1, \dots, Y_{n_2} iid.
- Échantillon **appariées** $(X_1, Y_1), \dots, (X_n, Y_n)$ sont iid $X_1 \perp Y_1$

On note $Z_i = Y_i - X_i$. On suppose que Z_i a une fonction de répartition continue donc aucun des Z_i ne vaut 0.

Conditions

Fonction de répartition continue.

Hypothèse

- H_0 La médiane de Z vaut 0. $m_Z = 0$. C'est à dire que $P(Y_1 < X_1) = 1/2$
- $H_1 = m_Z \neq 0$ ou $m_Z > 0 \Leftrightarrow P(Z \leq 0) > 1/2 \Leftrightarrow P(Y_1 > X_1) > 1/2$ ou $m_Z < 0$

Statistique de test

$$S_n = \sum_{i=1}^n \mathbb{1}_{Z_i \leq 0} \\ = \text{Nombre de } Y_i > X_i$$

Zone de Rejet

— Sous $H_0 : P(Z_i > 0) = P(Y_i > X_i) = \frac{1}{2}$

$$\mathbb{1}_{Z_i > 0} \sim \text{Ber}\left(\frac{1}{2}\right).$$

donc

$$S_n \sim \text{Bin}\left(n, \frac{1}{2}\right).$$

— Sous H_1

— Si $m_z > 0, P(Y_i > X_i) > \frac{1}{2}, S_n \sim \text{Bin}(n, p), p > \frac{1}{2}$ donc S_n est "grand"

— Si $m_z < 0, P(Y_i < X_i) > \frac{1}{2}$ donc S_n est petit.

— Si $m_z \neq 0, S_n$ a un comportement proche des extremes (petit/grand).

On utilise donc une table de la loi binomiale. Si n est grand, on utilise le TCL.

Méthode

$$\sum_k^{l=1} n_l (\bar{Y}_l - \bar{Y})^2 \sum_k^{l=1} \sum_{n_l}^{i=1} (Y_i^l - \bar{Y}_l) \bar{Y}_l = \frac{1}{n_l} \sum_{n_l}^{i=1} X_i^l.$$

10 Signe et Rang

Donnée

Conditions

Hypothèse

Statistique de test

Zone de Rejet

Méthode

11 Test d'indépendance de Pearson

Donnée

Conditions

Hypothèse

Statistique de test

Zone de Rejet

Méthode

12 Test de comparaison asymptotique de proportion

Donnée

Conditions

Hypothèse

Statistique de test

Zone de Rejet

Méthode

13 ANOVA

Donnée

- $X_1^{(1)}, \dots, X_{n_1}^{(1)}$ va iid $\mathcal{N}(m, \sigma_1^2)$
- $X_1^{(2)}, \dots, X_{n_2}^{(2)}$ va iid $\mathcal{N}(m, \sigma_2^2)$
- $X_1^{(K)}, \dots, X_{n_K}^{(K)}$ va iid $\mathcal{N}(m, \sigma_K^2)$

Conditions

- Échantillon gaussien indépendant de même variance
- On suppose de plus l'**homoscédasticité** : $\sigma_1^2 = \dots = \sigma_K^2$
- K échantillons **indépendants**

Hypothèse

- $H_0 = m_1 = \dots = m_k$
- $H_1 = \exists i, j tq m_i \neq m_j$

Statistique de test

$$SCE_{intra}^{totale} = \sum_{p=1}^K SCE^{(p)}.$$

$$\bar{X} = \text{moyenne totale} = \frac{1}{n} \sum_{p=1}^K n_p \bar{X}^{(p)}.$$

$$SCE_{inter} = \sum_{p=1}^K n_p (\bar{X}^{(p)} - \bar{X})^2.$$

Zone de Rejet

$$F = \frac{SCE_{inter}/(K-1)}{SCE_{intra}^{totale}/(n-K)}.$$

Sous $H_0 : F \sim \mathcal{F}(K-1, n-K)$

Sous H_1 , F prend de grande valeurs.

Méthode

Tout calculer jusqu'à la stat de test.

— Si la loi de Fisher est trop grande. On se souvient que

$$\begin{aligned} \frac{\chi^2(k)}{k} &\xrightarrow{k \rightarrow +\infty} 1 \\ \Rightarrow F &= \frac{SCE_{inter}/(K-1)}{SCE_{intra}^{totale}/(n-K)} \rightarrow \frac{SCE_{inter}/(K-1)}{1} \\ &= \chi^2(K-1)/K-1 \end{aligned}$$

— Si on ne nous donne pas SCE directement on sait que

$$SCE^{(p)} = \sum_{i=1}^{n_p} (X_i^{(p)} - \bar{X}^{(p)})^2 = (n_p - 1)V^{(p)}.$$